

# 数值分析第三次大作业

张晋

学号：15091060

最后更新于：May 28, 2017

# 目录 | 0

1	题目	2
2	算法设计方案	4
2.1	方案	4
2.2	Newton 迭代法	5
2.3	分片双二次插值	6
2.4	曲面拟合	7
3	问题求解	9
4	源程序	10
4.1	C 语言版大作业	10
5	计算结果	12
6	讨论	14

关于  $x, y, t, u, v, w$  的下列方程组:

$$\begin{cases} 0.5 \cos t + u + v + w - x = 2.67 \\ t + 0.5 \sin u + v + w - y = 1.07 \\ 0.5t + u + \cos v + w - x = 3.74 \\ t + 0.5u + v + \sin w - y = 0.79 \end{cases}$$

以及关于  $z, t, u$  的下列二维数表确定了一个二元函数  $z = f(x, y)$ 。

表 1.1: 二维数表

$z \backslash y$ $t$	0	0.4	0.8	1.2	1.6	2
0	-0.5	-0.34	0.14	0.94	2.06	3.5
0.2	-0.42	-0.5	-0.26	0.3	1.18	2.38
0.4	-0.18	-0.5	-0.5	-0.18	0.46	1.42
0.6	0.22	-0.34	-0.58	-0.5	-0.1	0.62
0.8	0.78	-0.02	-0.5	-0.66	-0.5	-0.02
1	1.5	0.46	-0.26	-0.66	-0.74	-0.5

1. 试用数值方法求出  $f(x, y)$  在区域  $D = \{(x, y) | 0 \leq x \leq 0.8, 0.5 \leq y \leq 1.5\}$  上的一个近似表达式:

$$p(x, y) = \sum_{r=0}^k \sum_{s=0}^k c_{rs} x^r y^s$$

要求  $p(x, y)$  最小的  $k$  值达到以下的精度:

$$\sigma = \sum_{i=0}^{10} \sum_{j=0}^{20} [f(x_i, y_j) - p(x_i, y_j)]^2 \leq 10^{-7}$$

其中,  $x_i = 0.08i, y_j = 0.5 + 0.05j$

2. 计算  $f(x_i^*, y_j^*), p(x_i^*, y_j^*)$  ( $i = 1, 2, \dots, 8; j = 1, 2, \dots, 5$ ) 的值, 以观察  $p(x, y)$  逼近  $f(x, y)$  的效果, 其中  $x_i^* = 0.1i, y_j^* = 0.5 + 0.2j$

### 说明:

1. 用迭代方法求解非线性方程组时, 要求近似解向量  $\mathbf{x}^{(k)}$  满足以下精度

$$\frac{\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|_{\infty}}{\|\mathbf{x}^{(k)}\|_{\infty}} \leq 10^{-12}$$

2. 作二元插值时, 要使用分片二次代数插值。
3. 要由程序自动确定最小的  $k$  值。
4. 打印以下内容:
  - (a) 全部源程序;
  - (b) 数表:  $\{x_i, y_j, f(x_i, y_j)\}$  ( $i = 0, 1, 2, \dots, 10; j = 0, 1, 2, \dots, 20$ );
  - (c) 选择过程的  $k, \sigma$  值;
  - (d) 达到精度要求时的  $k$  和  $\sigma$  值以及  $p(x, y)$  中的系数  $c_{rs}$  ( $r = 0, 1, \dots, k; s = 0, 1, \dots, k$ );
  - (e) 数表:  $\{x_i^*, y_j^*, f(x_i^*, y_j^*), p(x_i^*, y_j^*)\}$  ( $i = 1, 2, \dots, 8; j = 1, 2, \dots, 5$ )。
5. 采用  $f$  型输出  $x_i, y_j, x_i^*, y_j^*$  的准确值, 其余实型数采用  $e$  型输出并且至少显示 12 位有效数字。

2.1 方案	4
2.2 Newton 迭代法	5
2.3 分片双二次插值	6
2.4 曲面拟合	7

## 2.1 方案

1. 将  $x_i = 0.08i, y_j = 0.5 + 0.05j$  ( $i = 0, 1, \dots, 10; j = 0, 1, \dots, 20$ ) 代入非线性方程组 (2.1) 中, 用Newton 迭代法解出  $t_{ij}$  和  $u_{ij}$ ;
2. 对数表  $z(t, u)$  进行分片双二次插值, 求得  $z_{ij} = \hat{z}(t_{ij}, u_{ij})$
3. 根据  $z_{ij}$  的值进行曲面拟合, 要求精度  $\sigma \leq 10^{-7}$ , 得拟合函数

$$p(x, y) = \sum_{r=0}^k \sum_{s=0}^k c_{rs} x^r y^s$$

4. 创建新的数据点集  $x_i^* = 0.1i, y_j^* = 0.5 + 0.2j$  ( $i = 1, 2, \dots, 8; j = 1, 2, \dots, 5$ ), 并代入非线性方程组 (2.1) 中, 用Newton 迭代法解出  $t^*$  和  $u^*$ , 再用分片双二次插值计算出  $f(x^*, y^*)$ , 将其与  $p(x^*, y^*)$  输出并观察比较。

## 2.2 Newton 迭代法

$$\begin{cases} 0.5 \cos t + u + v + w - x = 2.67 \\ t + 0.5 \sin u + v + w - y = 1.07 \\ 0.5t + u + \cos v + w - x = 3.74 \\ t + 0.5u + v + \sin w - y = 0.79 \end{cases} \quad (2.1)$$

对于该非线性方程组来说,  $x, y$  为已知量, 需解出  $t, u, v, w$ 。设  $\mathbf{x} = (t, u, v, w)^T$ , 并设定精度水平  $\varepsilon = 10^{-12}$  和最大迭代次数  $M$  先在  $\mathbf{x}^*$  附近选取  $\mathbf{x}^{(0)} = (t^{(0)}, u^{(0)}, v^{(0)}, w^{(0)})^T$  然后迭代<sup>1</sup>:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [\mathbf{F}'(\mathbf{x}^{(k)})]^{-1} \mathbf{F}(\mathbf{x}^{(k)})$$

具体算法如下:

---

### Algorithm 1 Newton's method

---

```

1: Set  $\mathbf{x}^{(0)} \in D$  and  $k = 0$ 
2: while  $k < M$  do
3:   Compute  $\mathbf{F}(\mathbf{x}^{(k)})$  and  $\mathbf{F}'(\mathbf{x}^{(k)})$ 
4:   Compute  $\Delta \mathbf{x}^{(k)} = -[\mathbf{F}'(\mathbf{x}^{(k)})]^{-1} \mathbf{F}(\mathbf{x}^{(k)})$ 
5:   if  $\|\Delta \mathbf{x}^{(k)}\| / \|\mathbf{x}^{(k+1)}\| \leq \varepsilon$  then
6:      $\mathbf{x}^* = \mathbf{x}^{(k)}$ 
7:     Break
8:   end if
9:    $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)}$ 
10:   $k = k + 1$ 
11: end while

```

---

其中, 基于方程组 (2.1) 的雅可比矩阵  $\mathbf{F}(\mathbf{x})$ ,  $\mathbf{F}'(\mathbf{x})$  分别为:

$$\mathbf{F}(\mathbf{x}) = \begin{bmatrix} 0.5 * \cos(t) + u + v + w - x - 2.67 \\ t + 0.5 * \sin(u) + v + w - y - 1.07 \\ 0.5 * t + u + \cos(v) + w - x - 3.74 \\ t + 0.5 * u + v + \sin(w) - y - 0.79 \end{bmatrix}$$

$$\mathbf{F}'(\mathbf{x}) = \begin{bmatrix} -0.5 * \sin(t) & 1 & 1 & 1 \\ 1 & 0.5 * \cos(u) & 1 & 1 \\ 0.5 & 1 & -\sin(v) & 1 \\ 1 & 0.5 & 1 & \cos(w) \end{bmatrix}$$

---

<sup>1</sup>迭代的终止条件为  $\|\Delta \mathbf{x}^{(k)}\| / \|\mathbf{x}^{(k+1)}\| \leq \varepsilon$ , 若  $k > M$  时仍未达到迭代精度, 则迭代失败。

## 2.3 分片双二次插值

前面我们将  $\{(x_i, y_j)\}$  代入非线性方程组 (2.1) 中, 然后用Newton 迭代法解出了  $t_{ij}$  和  $u_{ij}$ .

在这一节中我们需要根据表1.1对  $z(t, u)$  进行分片双二次插值, 求得  $z_{ij} = \hat{z}(t_{ij}, u_{ij})$  ( $i = 0, 1, 2, \dots, 10; j = 0, 1, 2, \dots, 20$ ).

因为表1.1为  $6 \times 6$  的数表, 故可设:

$$t_i = ih \quad (i = 0, 1, \dots, 5)$$

$$u_j = j\tau \quad (j = 0, 1, \dots, 5)^2$$

对于给定的  $(t, u)$ , 如果  $(t, u)$  满足:

$$t_i - \frac{h}{2} < t \leq t_i + \frac{h}{2}, \quad 2 \leq i \leq 3$$

$$u_j - \frac{\tau}{2} < u \leq u_j + \frac{\tau}{2}, \quad 2 \leq j \leq 3$$

那么应选择  $(t_k, u_r)$  ( $k = i - 1, i, i + 1; r = j - 1, j, j + 1$ ) 为插值节点。

若  $t$  满足:

$$t \leq t_1 + \frac{h}{2}$$

或

$$t > t_4 + \frac{h}{2}$$

则相应地选取  $i = 1$  或  $i = 4$

同样的, 若  $u$  满足:

$$u \leq u_1 + \frac{\tau}{2}$$

或

$$u > u_4 + \frac{\tau}{2}$$

则相应地选取  $j = 1$  或  $j = 4$

最后得到插值多项式为

$$\hat{z}(t, u) = \sum_{k=i-1}^{i+1} \sum_{r=j-1}^{j+1} l_k(t) \tilde{l}_r(u) z(t_k, u_r) \quad (2.2)$$

其中,

$$l_k(t) = \prod_{\substack{m=i-1 \\ m \neq k}}^{i+1} \frac{t - t_m}{t_k - t_m} \quad (k = i - 1, i, i + 1)$$

$$\tilde{l}_r(u) = \prod_{\substack{n=j-1 \\ n \neq r}}^{j+1} \frac{u - u_n}{u_r - u_n} \quad (r = j - 1, j, j + 1)$$

---

<sup>2</sup>其中,  $h = 0.2, \tau = 0.4$

## 2.4 曲面拟合

设在三维坐标系  $Oxyu$  中给定  $(m+1) \times (n+1)$  个点:

$$\mathfrak{D} = \{(x_i, y_j), z_{ij}\} \quad (i = 0, 1, \dots, m; j = 0, 1, \dots, n) \quad (2.3)$$

选定  $M+1$  个  $x$  的函数  $\{\varphi_r(x)\}_{r=0}^M$  和  $N+1$  个  $y$  的函数  $\{\psi_s(y)\}_{s=0}^N$

以函数组  $\{\varphi_r(x)\psi_s(y)\} \quad (r = 0, 1, \dots, M; s = 0, 1, \dots, N)$  为基函数, 构成以  $\{c_{rs}\}$  为参数的曲面族

$$p(x, y) = \sum_{r=0}^M \sum_{s=0}^N c_{rs} \varphi_r(x) \psi_s(y) \quad (2.4)$$

若参数  $\{c_{rs}^*\}$  使得

$$\sum_{i=0}^m \sum_{j=0}^n \left[ \sum_{r=0}^M \sum_{s=0}^N c_{rs}^* \varphi_r(x_i) \psi_s(y_j) - u_{ij} \right]^2 = \min$$

成立, 则称相应曲面  $p^*(x, y)$  为在曲面族 (??) 中按最小二乘原则确定的对于数据 (2.3) 的拟合曲面。

可证得<sup>3</sup>, 拟合曲面的系数矩阵为

$$\mathbf{C} = (\mathbf{B}^T \mathbf{B})^{-1} \mathbf{B}^T \mathbf{U} \mathbf{G} (\mathbf{G}^T \mathbf{G})^{-1} \quad (2.5)$$

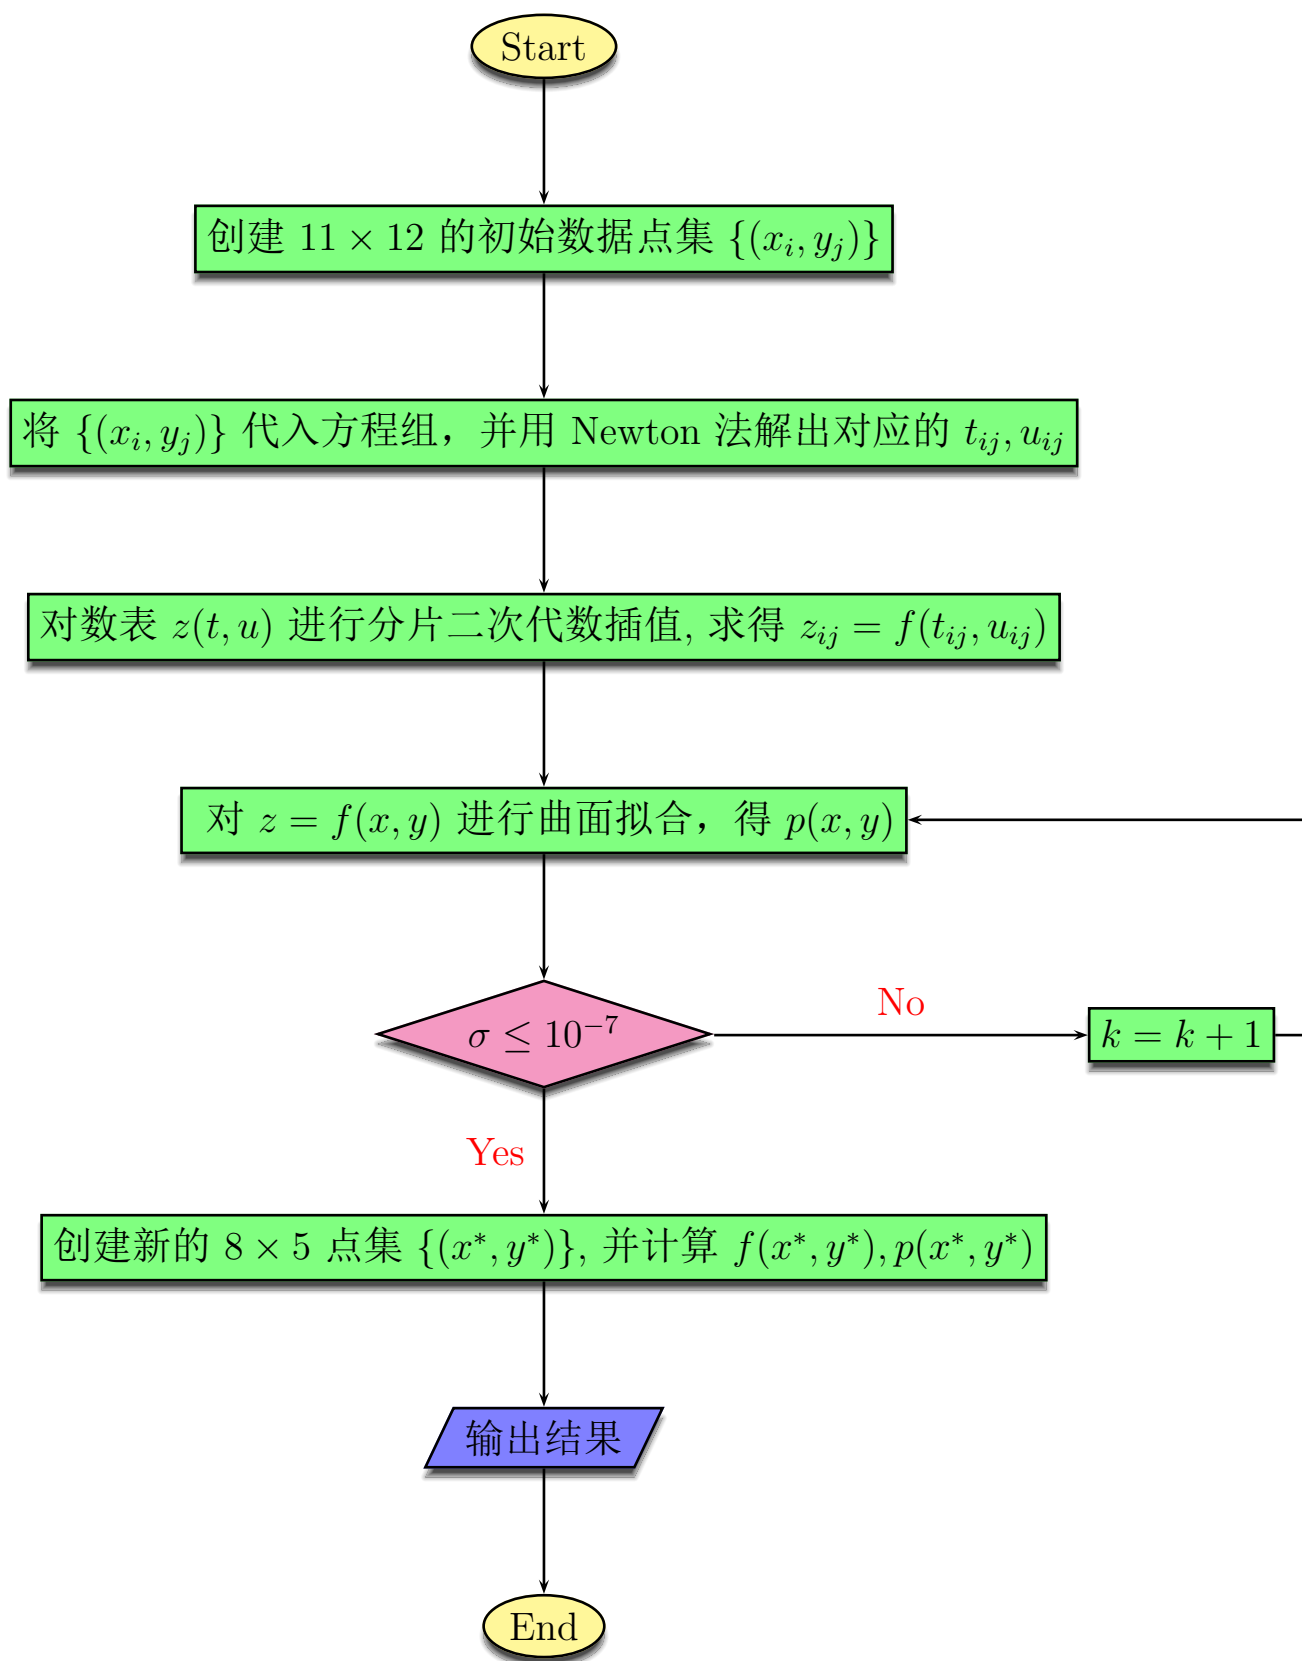
$$\mathbf{B} = [\varphi_r(x_i)]_{(m+1) \times (M+1)} = \begin{bmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_M(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_M(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_0(x_m) & \varphi_1(x_m) & \cdots & \varphi_M(x_m) \end{bmatrix}$$

$$\mathbf{U} = \begin{bmatrix} z_{0,0} & z_{0,1} & \cdots & z_{0,20} \\ z_{1,0} & z_{1,1} & \cdots & z_{1,20} \\ z_{2,0} & z_{2,1} & \cdots & z_{2,20} \\ \vdots & \vdots & \ddots & \vdots \\ z_{10,0} & z_{10,1} & \cdots & z_{10,20} \end{bmatrix}$$

---

<sup>3</sup>在讨论中, 我将给出一种与教材不一样的证明方法





1. 初始化定义  $A$  矩阵
2. 采用 *Householder* 变化将  $A$  矩阵拟上三角化得到矩阵  $A^{n-1}$
3. 采用  $QR$  分解将矩阵  $A^{n-1}$  分解为矩阵  $Q$  与  $R$ ，并打印  $RQ$
4. 用带双步位移的  $QR$  方法求解所有特征值
5. 用 Gauss 消去法求解  $(A - \lambda I)X = 0$ , 得到对应的特征向量
6. 输出

4.1 C 语言版大作业	10
--------------	----

## 4.1 C 语言版大作业

```
1  #include<stdio.h>
2  #include<math.h>
3  #include<string.h>
4  #define N 20
5  const double eps=1e-12;
6  double a[N][N],B[N][N],C[N][N];
7  int n=10;
8
9  typedef struct{
10 //定义复数结构体
11     double Re;
12     double Im;
13 }ComplexNumber;
14
15
16 int main(){
17     double Q[N][N];
18     freopen("Works.in","r",stdin);
19     freopen("Works.out","w",stdout);
20     def();
21     Householder_Triangularization(a);
22     printf("A_n-1:\n");
23     output(a);
24     QR(a,Q);
25     printf("\nR:\n");
26     output(a);
27     printf("\nQ:\n");
28     output(Q);
29     memset(B,0,sizeof(B));
30     MatirixM_M(a,Q);
```

```
31     printf("\nR*Q:\n");
32     output(B);
33     def();
34     DQR(a);
35     return 0;
36 }
```

计算结果 | 5

后面为输出结果:

特征值与向量如下:

$$\lambda_1 = 9.432879572769e - 001$$

$$\text{Eigenvector}=(0.079620, \quad 0.045421, \quad -0.018272, \quad -0.047961, \quad -0.349567, \quad 0.207215, \\ -0.152312, \quad 0.820634, \quad -0.355466, \quad 0.028866)$$

$$\lambda_2 = 6.489488202110e - 001$$

$$\text{Eigenvector}=(0.108435, \quad 0.071344, \quad 0.382502, \quad -0.047100, \quad -0.717804, \quad 0.181519, \\ -0.226006, \quad 0.388381, \quad 0.289696, \quad 0.024333)$$

$$\lambda_3 = -9.891143464725e - 001 + i*1.084758631513e-001$$

$$\lambda_4 = -9.891143464725e - 001 - i*1.084758631513e-001$$

$$\lambda_5 = 4.954990923624e - 002$$

$$\text{Eigenvector}=(-0.213768, \quad -0.206774, \quad 0.386829, \quad -0.031112, \quad -0.380939, \quad -0.125174, \\ 0.644716, \quad -0.308201, \quad -0.295977, \quad 0.043723)$$

$$\lambda_6 = -1.493147080915e + 000$$

$$\text{Eigenvector}=(-0.561341, \quad 0.778192, \quad 0.014364, \quad -0.277602, \quad 0.003568, \quad -0.002548, \\ -0.022061, \quad -0.011758, \quad -0.013173, \quad 0.035016)$$

$$\lambda_7 = 1.590313458807e + 000$$

$$\text{Eigenvector}=(0.062377, \quad -0.011231, \quad -0.252846, \quad -0.130988, \quad -0.381985, \quad 0.815575, \\ -0.123377, \quad -0.067721, \quad 0.271945, \quad 0.100282)$$

$$\lambda_8 = -2.336865932238e + 000 + i*8.934379210213e-001$$

$$\lambda_9 = -2.336865932238e + 000 - i*8.934379210213e-001$$

$$\lambda_{10} = 3.389613438816e + 000$$

$$\text{Eigenvector}=(-0.104872, \quad -0.217677, \quad -0.474694, \quad -0.259384, \quad -0.304665, \quad -0.259452, \\ 0.086866, \quad 0.405258, \quad 0.509628, \quad 0.239515)$$

1. 在对  $n \times n$  实矩阵  $\mathbf{A}$  作 QR 分解或双步位移分解时不需要形成具体的矩阵  $\mathbf{H}_i$ , 这样可以避免矩阵与矩阵相乘, 大大减少了计算量。

2. 在 QR 分解中, R 矩阵可以直接储存在 A 的上三角部分, 而在  $M_k$  的 QR 分解中, 不需要再生成  $\mathbf{B}, \mathbf{C}$  矩阵, 直接在  $\mathbf{M}, \mathbf{A}$  矩阵中迭代即可, 以节约储存空间。

3. QR 方法适用于计算一般实矩阵的全部特征值, 但对于大型实矩阵, 则收敛速度不够用了, 这时我们为了加速收敛, 可以引入位移量, 通常, 位移越离特征值越近, 收敛速度就越快, 如果位移  $\sigma$  与某个特征值非常接近, 则  $\mathbf{A}_{n,n}^{(k)} - \sigma$  就非常接近于 0. 这说明  $\mathbf{A}_{n,n}^{(k)}$  通常会首先收敛到  $\mathbf{A}$  的一个特征值. 所以令  $\sigma = \mathbf{A}_{n,n}^{(k)}$  是一个不错的选择. 但是, 如果这个特征值是复数, 这种位移选取方法就可能失效.

假设  $\sigma \in \mathbb{C}$  是  $\mathbf{A}$  的某个复特征值  $\lambda$  的一个很好的近似, 则其共轭  $\bar{\sigma}$  也应该是  $\bar{\lambda}$  的一个很好的近似. 因此我们可以考虑**双位移策略**, 即先以  $\sigma$  为位移迭代一次, 然后再以  $\bar{\sigma}$  为位移迭代一次, 如此不断交替进行迭代. 这样就有

$$\begin{aligned} A_1 - \sigma I &= Q_1 R_1, \\ A_2 &= R_1 Q_1 + \sigma I, \\ A_2 - \bar{\sigma} I &= Q_2 R_2, \\ A_3 &= R_2 Q_2 + \bar{\sigma} I. \end{aligned}$$

容易验证

$$A_3 = Q_2^T A_2 Q_2 = Q_2^* Q_1^* A_1 Q_1 Q_2 = Q^* A_1 Q,$$

其中  $Q = Q_1 Q_2$ .

我们注意到  $\sigma$  可能是复的, 所以  $Q_1$  和  $Q_2$  都可能是复矩阵. 但我们却可以选择适当的  $Q_1$  和  $Q_2$ , 使的  $Q = Q_1 Q_2$  是实正交矩阵从而  $A_3 = Q^T A_1 Q$  也是实矩阵. 因此我们无需计算  $A_2$ , 而是直接由  $A_1$  计算出  $A_3$ .

4. 最后, 在用 Gauss 消去法求解  $(A - \lambda I)X = 0$ , 求得到对应的特征向量时, 需要将  $X[n]$  预设为 1, 因为由于线性方程组  $AX = b$  中的  $b$  向量全为 0, 所以解的自由度为 1, 需要自己先将  $X[n]$  的值定下来, 才能迭代出剩下的解, 不然求出的解全为 0.